

TRABAJO FIN DE MÁSTER · GRUPO K1 · MP6

E-Commerce Sales Forecast

Análisis Predictivo y Segmentación de Clientes

Jesús Alonso Cendrero · Aleix Bermúdez Arnau
Lucas Chacón Langa · Diego Darachaga Leon

Máster en IA y Big Data

Estructura de la presentación

01 Contexto del Proyecto

Dataset de 500K+ transacciones, stack tecnológico y pipeline de preprocesado

03 Clustering

Segmentación de clientes: perfiles VIP, Recurrentes y Ocasionales

02 Regresión

Predicción de ventas diarias con Random Forest, XGBoost y LightGBM

04 Conclusiones

Logros alcanzados y próximos pasos para ambas líneas de trabajo

CONTEXTO DEL PROYECTO

El Dataset

Dataset *E-Commerce Data* de la Universidad de California (Kaggle). Transacciones online de una tienda del Reino Unido especializada en regalos únicos.

500K+ transacciones online

12 meses de datos (Dic 2010 – Dic 2011)

8 campos por transacción

CAMPOS DEL DATASET

`InvoiceNo` ID factura · prefijo "C" = cancelación

`Quantity` Unidades · valor negativo = devolución

`UnitPrice` Precio unitario en libras esterlinas (£)


`CustomerID` ID del cliente · puede estar ausente

`InvoiceDate` Fecha y hora exacta de la transacción

`Country` País de origen del cliente

Pipeline de preparación

Los profesionales del dato dedican ~60% de su tiempo al preprocesado — *"garbage in, garbage out"*



01


Regresión **Predicción de Ventas**

Estimación de ventas diarias mediante
ensambles de árboles de decisión para optimizar
inventarios y decisiones de negocio



División cronológica del dataset

En series temporales, los datos futuros nunca pueden entrar en el entrenamiento (look-ahead bias)



Entrenamiento

El modelo aprende los patrones históricos de las ventas diarias durante 10 meses completos.

Validación

Comparar modelos y ajustar hiperparámetros sin contaminar el conjunto de test final.

Test

Simulación real: el modelo predice el futuro que nunca ha visto. Evaluación final inamovible.

Variable objetivo: `TotalVenta` — suma diaria de todos los importes ($\text{Quantity} \times \text{UnitPrice}$)

Variables de series temporales

Los algoritmos de ML no entienden el tiempo de forma nativa — hay que codificarlo como variables numéricas

lag Variables de rezago

lag_1

Ventas del día anterior — inercia inmediata del mercado

lag_7

Ventas de hace 7 días —
estacionalidad semanal, la más potente

avg Media móvil

media_7

Promedio de los últimos 7 días. Suaviza el ruido y captura la tendencia reciente.

`shift(1)` previo evita filtración de datos futuros

OHE Día de la semana

dia_semana_0 ... 6

One-Hot Encoding: una columna binaria por día. Captura variación semanal sin imponer orden numérico.

Sin `dia_semana_5` — sin ventas en sábados

Tres modelos en competencia

Random Forest

Baseline

Múltiples árboles de decisión independientes cuyo promedio reduce varianza. El más interpretable de los tres.

```
n_estimators=100
random_state=42
```

XGBoost

Challenger

Gradient Boosting secuencial: cada árbol aprende de los errores del anterior. Más potente, más sensible a overfitting.

```
n_estimators=100
learning_rate=0.05
```

LightGBM

Ganador

Variante leaf-wise de Microsoft: más rápido y frecuentemente más preciso que el nivel-wise estándar.

```
n_estimators=100
learning_rate=0.05 verbose=-1
```


Comparativa sobre el set de validación

MAE y RMSE calculados exclusivamente en validación — nunca en test

MODELO	MAE (£)	RMSE (£)
Random Forest	≈ 13.500	≈ 18.900
XGBoost	≈ 12.800	≈ 17.400
LightGBM 	11.079	15.397

El criterio de selección es siempre cuantitativo: menor error en validación, nunca en test.

MAE — ERROR MEDIO

£11.079


El modelo se equivoca de media £11k/día

RMSE — ERRORES EXTREMOS

£15.397

Penaliza picos — diferencia controlada respecto al MAE

Dashboard de validación del modelo



02

Clustering Segmentación de Clientes

Aprendizaje no supervisado para identificar
perfiles de comportamiento y habilitar estrategias
de marketing diferenciadas

Del dataset de transacciones al perfil de cliente

De 500.000+ líneas a 4.338 perfiles únicos mediante `groupby(CustomerID)`

4 VARIABLES DE COMPORTAMIENTO

`TotalGastado`

Suma total de compras.
Indicador directo del valor
aportado.

`NumCompras`

Facturas únicas. Mide la
frecuencia de interacción.

`ProductosDistintos`

StockCodes únicos.
Explorador de catálogo vs.
recurrente.

`TicketMedio`

$\text{TotalGastado} \div \text{NumCompras}$.
Importe por visita.

Pipeline de clustering

- **Isolation Forest** — 217 outliers eliminados (5%)
- **RobustScaler** — escalado por mediana e IQR
- **PCA** — PC1 explica el 62.63% de la varianza
- **Método del codo** — k=3 óptimo
- **K-Means · Jerárquico · DBSCAN**

Resultado

4.121 perfiles limpios listos para segmentar

Tres algoritmos, un resultado consistente

K-Mean

Modelo final

Sentroides claros, eficiente en re-entrenamiento. `means` evita mínimos locales.

0.618

Silhouette Score

Jerárquico

Validación

Construye grupos de abajo hacia arriba. Resultado prácticamente idéntico a K-Means: los grupos son reales.

0.621

Silhouette Score

DBSCAN

Contraste

Sin número fijo de clusters. No detecta subgrupos ocultos: una masa principal + ruido en extremos.

Confirma que k=3 no simplifica en exceso

Silhouette Score > 0.6 | Clusters bien separados y compactos — segmentación consistente y accionable

Los tres segmentos de clientes

SEGMENTO A

VIP / Premium

402

clientes · 9.75%

£4.179 gasto medio

~10 compras / año

~145 productos distintos

Fidelización, acceso anticipado a
productos, atención premium

SEGMENTO B

Recurrentes

1.132

clientes · 27.47%

£1.624 gasto medio

4 – 5 compras / año

~80 productos distintos

Recomendaciones personalizadas,
programas de puntos, cross-selling

SEGMENTO C

Ocasionales

2.587

clientes · 62.78%

£408 gasto medio

1 – 2 compras / año

Pocos productos distintos

Campañas de reactivación, descuentos
por recompra, retención

Dashboard de segmentación de clientes



CONCLUSIONES

Logros del proyecto

REGRESIÓN

Pipeline completo sobre 500K+ registros en bruto: EDA, limpieza justificada y feature engineering

Variables temporales: lag_1, lag_7 y media_7 dotan al modelo de memoria histórica

LightGBM seleccionado: MAE **£11.079** y RMSE **£15.397**

Dashboard Power BI con métricas DAX: MAE, RMSE, MAPE y % desviación total

CLUSTERING

4 variables de comportamiento condensan información de 500K+ transacciones por cliente

PC1 del PCA resume el **62.63%** de la varianza; 217 outliers eliminados con Isolation Forest

K-Means k=3 con Silhouette **0.618** , confirmado por Jerárquico (0.621) y DBSCAN

Segmentos **VIP** · **Recurrentes** · **Ocasionales** con perfiles y acciones de marketing diferenciadas


Líneas de trabajo futuras

REGRESIÓN

- 01** Pruebas ajustando hiperparámetros del modelo ganador LightGBM
- 02** Explorar modelos complementarios ARIMA y Prophet para comparar modelos estadísticos con ML
- 03** Exportar el modelo y hacer uso de él en una aplicación web

CLUSTERING

- 04** Variables RFM completas: incorporar Recency (tiempo desde última compra)
- 05** Cruzar clusters con Country para detectar mercados geográficos clave
- 06** Conectar segmentos con el modelo de regresión para estimar su contribución a las ventas predichas



Gracias

TFM E-Commerce Sales Forecast · Grupo K1 · MP6

Jesús Alonso Cendrero

Aleix Bermúdez Arnau

Lucas Chacón Langa

Diego Darachaga Leon